5 실험

우리는 Eso-LM을 두 가지 표준 언어 모델링 벤치마크인 One Billion Words 데이터셋(LM1B)

5.1 우도 평가

우리의 실험 결과, Eso-LM은 LM1B와 OWT에서 확산 모델 중 최첨단 퍼플렉시티를 달성하며, MDM과 AR 퍼플렉시티 간에 더 미세한 보간을 제공한다(표 1 및 표 2).

실험 설정 우리는 Eso-LM을 선도적인 마스크 확산 모델(MDLM

결과 우리의 방법의 PPL은 (7)을 사용하여 계산된다. LM1B에서 우리는 $\alpha_0 \in 0.0625, 0.125, 0.25, 0.5, 1.0$으로 Eso-LM (A)를 훈련하고, $\alpha_0 = 1$으로 Eso-LM (B)를 훈련한다. 우리는 Eso-LM (A)가 MDLM과 AR 퍼플렉시티 사이를 효과적으로 보간함을 발견한다. 놀랍게도, 마스크 토큰에 대한 양방향 어텐션을 인과 마스크로 대체하여 MDM을 수정한 Eso-LM (A)는 ≈ 1에서 MDLM보다 $\alpha_0 = 1$ PPL만큼 우수하다. 이러한 개선은 앞서 설명한 저분산 훈련 손실에 기인할 수 있다. 대조적으로, Eso-LM (B)는 깨끗한 토큰들 사이에 인과적 의존성을 도입하여 ≈ 4에서 Eso-LM (A)보다 $\alpha_0 = 1$ PPL만큼 성능이 저하된다. 이는 Eso-LM (A)의 깨끗한 토큰에 대한 양방향 어텐션이 Eso-LM (B)의 인과적 어텐션보다 표현력이 엄격하게 더 크기 때문에 예상되는 결과이다. OWT에서 Eso-LM (B)는 확산 단계에서 KV 캐싱을 지원하는 유일한 모델(BD3-LM 포함)이므로 특히 설득력이 있다. $\alpha_0 \in 0.0625, 0.125, 0.25, 0.5, 1.0$으로 훈련된 이 모델은 AR과 MDM 퍼플렉시티 사이의 부드러운 보간을 보여준다(표 2). LM1B와 마찬가지로, Eso-LM (A)는 OWT에서 MDLM과 경쟁력이 있다.

5.2 생성 속도

우리의 정성적 평가 실험에 따르면 Eso-LM은 KV 캐싱을 지원하는 이전 확산 기반 방법보다 3–4× 빠르고, KV 캐싱을 지원하지 않는 MDM보다 최대 65× 빠르다.

실험 설정 MDLM과 같은 확산 모델은 양방향 어텐션을 사용하기 때문에 KV 캐싱을 지원하지 않는다. BD3-LM과 같은 반자동회귀 모델은 토큰 블록을 자동회귀 방식으로 생성하고 완료된 블록을 캐싱함으로써 부분적인 KV 캐싱을 가능하게 하지만, 확산 중인 현재 블록에 대한 캐싱은 여전히 부족하다. 반면, 우리의 방법은 확산 단계에서 KV 캐싱을 독특하게 지원한다. 우리는 우리의 방법인 Eso-LM (B)의 추론 시간을 MDLM 및 BD3-LM과 컨텍스트 길이 $L \in 2048, 8192$, 첫 번째 히팅 샘플러

표 1: LM1B의 테스트 퍼플렉시티(PPL; ↓). *He et al.

	PPL (↓)
Autoregressive	
Transformer†	22.83
Diffusion	
D3PM Uniform [2]	137.90$
D3PM Absorb [2]	76.90$
Diffusion-LM* [12]	118.62$

	PPL (↓)
DiffusionBert [7]	63.78
SEDD Absorb‡ [15]	32.71$
SEDD Uniform$ [15]	40.25$
MDLM‡ [26]	31.78
UDLM‡ [29]	36.71
DUO‡ [27]	33.68
Interpolating diffusion and autoregressive	
BD3-LMs† [1]	
L' = 16	30.60
L' = 8	29.83
L' = 4	28.23
Eso-LM (B) (Ours)	
α0 = 1.0	35.00
Eso-LM (A) (Ours)	
α0 = 1.0	30.96
α0 = 0.5	30.51
α0 = 0.25	28.44
α0 = 0.125	25.97
α0 = 0.0625	24.51

표 2: 25만 회 훈련된 모델의 OWT 테스트 퍼플렉시티(PPL; ↓). ‡

	PPL (↓)
Autoregressive	
Transformer	17.90$
Diffusion	
SEDD Absorb [15]	26.81$
MDLM [26]	25.76$
UDLM [29]	30.52$
DUO [27]	27.14$
Interpolating diffusion and autoregressive	
BD3-LMs [1]	
L' = 16	23.57†
Eso-LM (A) (Ours)	
α0 = 1	26.21

	PPL (↓)
Eso-LM (B) (Ours)	
$\alpha 0 = 1$	30.14
$\alpha 0 = 0.5$	27.85
$\alpha 0 = 0.25$	24.73
$\alpha 0 = 0.125$	21.87

표 3: 모든 방법에서 NFE를 L로 설정했을 때 시퀀스 길이 $L \in 2048,8192$에 대한 샘플링 시간 (↓)(초). 보고된 값은 5회 실행에 대한 평균입니다.

Method	L = 2048	L = 8192
AR (Oracle)	13.30.9	54.00.2
MDLM	201.30.4	5438.33.3
BD3-LM (L' = 4)	24.30.7	312.01.7
BD3-LM (L' = 16)	21.30.1	268.11.2
Eso-LM (B)	14.60.3	82.10.3

결과 표 3에서 보듯이, KV 캐싱이 없는 MDLM과 비교할 때, Eso-LM (B)는

~14×의 경우 L=2048배 빠르고, ~65×의 경우 L=8192배 빠르다. 부분적으로 캐싱을 지원하는 BD3-LM과 비교했을 때, Eso-LM (B)는 ~3.2×에서 BD3-LM ($L'=16$)보다 ~3.8×배 빠르고, BD3-LM ($L'=4$)보다 L=8192배 빠르다. 이러한 속도 향상은 KV 캐싱과 스케줄러 S에서 비롯된다. 이는 순방향 패스를 노이즈 제거될 마스크 토큰과 이전에 예측된 토큰으로 제한하여 중복 계산을 피한다. 이는 BD3-LM에는 없는 기능이다. NFE를 L으로 제한하면, 최종 노이즈 제거 단계에서만 가능한 지연된 KV 재사용으로 인해 AR 모델보다 우리 방법이 느리지만, 전반적인 효율성은 이전 확산 기반 기준선을 여전히 능가한다(섹션 4.2.2 참조).

5.3 생성 품질

우리의 샘플링 실험은 (1) Eso-LM이 샘플링 속도와 품질의 파레토 프론티어에서 새로운 SOTA를 구축하고(그림 4), (2) 높은 NFE에서 이전의 모든 확산 모델보다 고품질 샘플을 생성하며, (3) 이전의 보간 확산 방법인 BD3-LM과는 달리 낮은 NFE에서 모드 붕괴를 겪지 않음을 보여준다(그림 3).

실험 설정 우리는 $\alpha 0\text{train} \in 0.125,0.25,1$으로 Eso-LM (B)를 훈련하고, NFE를 제어하기 위해 다양한 $(\alpha 0\text{eval},T) \in 0.0625,0.25,0.5,1 \times 16,128,1024$을 사용하여 샘플을 생성한다(NFE = $|S|$). MDLM과 BD3-LM은 Sahoo et al.