난해한 언어 모델

Subham Sekhar Sahoo*[1] Zhihan Yang*[2] Yash Akhauri†[1] Johnna Liu†[1] Deepansha Singh†[1] Zhoujun Cheng†[3] Zhengzhong Liu[3] Eric Xing[3] John Thickstun[2] Arash Vahdat[4] *공동 제1 저자 †공동 제2 저자 [1] 코넬 테크 [2] 코넬 대학교 [3]MBZUAI [4] NVIDIA {ssahoo, zhihany}@cs.cornell.edu

초록

확산 기반 언어 모델은 병렬 및 제어 가능한 생성을 가능하게 함으로써 자기회귀(AR) 모델에 대한 매력적인 대안을 제공합니다. 이 모델 계열 중 마스크 확산 모델(MDM)은 가장 강력한 성능을 달성하지만, perplexity 면에서 여전히 AR 모델보다 떨어지고, KV 캐싱과 같은 핵심 추론 시간 효율성 기능이 부족합니다. 본 연구에서는 AR 및 MDM 패러다임을 융합하여 perplexity 면에서 부드러운 보간을 가능하게 하면서 각자의 한계를 극복하는 새로운 모델 계열인 Eso-LM을 소개합니다. Eso-LM은 표준 언어 모델링 벤치마크에서 새로운 최첨단 기술을 확립합니다. 결정적으로, 우리는 병렬 생성을 유지하면서 MDM에 KV 캐싱을 도입하여 추론 효율성을 크게 향상시킨 최초의 연구입니다. 최적화된 샘플링 스케줄과 결합된 우리의 방법은 표준 MDM보다 최대 65배, 이전의 반자기회귀 방식보다 4배 빠른 추론을 달성합니다. 코드와 모델 체크포인트는 프로젝트 페이지에서 제공합니다.

https://s-sahoo.com/Eso-LMs

1 서론

우리는 언어 모델링의 중요한 전환점에 서 있습니다. 패러다임 전환이 진행 중이며, 오랫동안 황금 표준으로 여겨졌던 자기회귀(AR) 언어 모델이 이제 표준 언어 생성 분야에서 확산 언어 모델과 경쟁하고 있습니다. 최근 연구 [26, 29]에 따르면 마스크 확산 모델(MDM)은 소규모 언어 벤치마크에서 AR 모델과의 격차를 좁히고 있으며, 분자 생성 [28, 11] 및 그래프 생성

이러한 결과는 MDM을 AR 모델에 대한 매력적인 대안으로 만듭니다. 그러나 MDM은 두 가지 주요 한계에 직면합니다. (1) 추론 속도: 병렬 생성을 지원함에도 불구하고, MDM은 KV 캐싱 부족(채팅 시스템과 같은 실시간 애플리케이션에 필수적인 최적화)으로 인해 실제로 AR 모델보다 훨씬 느립니다. (2) 생성 품질: MDM은 더 복잡한 언어 모델링 작업에서 여전히 눈에 띄는 가능성 격차를 보입니다

최근 제안된 BD3-LM

---

img-0.jpeg Figure 1: Efficient generation of an example sequence with our flagship model Eso-LM (B). During Diffusion Phase, Eso-LMs denoise one or more, potentially non- neighboring mask tokens (M) per step. During Sequential Phase, Eso-LMs denoise the remaining mask tokens one at a time from left to right. Eso-LM (B) allows for KV caching in both phases using just a single unified KV cache: blue bounding boxes enclose transformer cells that are building their KV cache; a cell becomes blue once its KV cache is built. The sequences below the transformers depict tokens in their natural order.

캐싱: KV 캐싱은 블록 간에 가능하지만, 블록 내 확산은 여전히 KV 지원이 부족하여 전반적인 속도 향상을 제한합니다.

이러한 문제들을 해결하기 위해 우리는 자기회귀 및 마스크 확산 접근 방식을 융합하는 새로운 언어 모델링 패러다임을 제안합니다. 우리 모델은 AR 및 MDM 목적 함수의 조합인 하이브리드 손실로 훈련되며, 이는 perplexity 측면에서 두

패러다임 사이를 부드럽게 보간할 수 있도록 합니다. 이를 위해서는 두 가지 핵심 혁신이 필요합니다. (1) AR 및 MDM 스타일의 생성을 모두 지원하기 위한 노이즈 제거 트랜스포머의 수정된 어텐션 메커니즘. (2) 확산 단계 내에서 KV 캐싱을 가능하게 하는 새로운 훈련 및 샘플링 절차. 이는 이전에 MDM에서는 사용할 수 없었던 기능입니다. 이 하이브리드 설계의 비전통적인 특성 때문에 우리는 우리 방법을 Eso-LM(Esoteric Language Models)이라고 명명했습니다.

우리의 방법은 언어 모델링 벤치마크에서 확산 모델 중 새로운 최첨단 기술을 확립하며, AR 및 MDM perplexity 사이의 보간에 대한 정교한 제어를 가능하게 합니다. 이전 접근 방식과 달리, 확산 중에 KV 캐싱을 지원하여 훨씬 빠른 추론을 가능하게 합니다. 요약하자면, 우리의 기여는 다음과 같습니다. (1) 우리는 AR 및 MDM 패러다임을 융합하고 이전 하이브리드 접근 방식인 BD3-LM을 능가하는 새로운 언어 모델링 프레임워크를 제안합니다. (2) 우리의 접근 방식은 MDM에 KV 캐싱을 가능하게 하면서 병렬 생성을 유지한 최초의 연구이며, 표준 MDM보다 최대 65×배, KV 캐싱된 반자기회귀 기준선보다 3−4×배 빠른 추론을 달성합니다(섹션 5.2). (3) 우리는 BD3-LM이 낮은 샘플링 단계에서 성능이 저하되는 반면, 우리의 방법은 낮은 NFE 체제에서는 MDM과, 높은 NFE 체제에서는 AR과 경쟁력을 유지함을 보여줍니다(섹션 5.3). (4) 우리의 결과는 이산 확산에 대한 새로운 최첨단 perplexity를 확립하여 자기회귀 모델과의 격차를 좁힙니다(섹션 5.1).

2 배경

표기법 우리는 K 값을 취할 수 있는 스칼라 이산 확률 변수를 '원-핫' 열 벡터로 표현하고, $\mathscr{V}\in\mathbf{x}\in0,1K:\Sigma i=1K\mathbf{x}i=1$을 그러한 모든 벡터의 집합으로 정의합니다. $\mathbf{m}\in\mathscr{V}$를 특별한 마스크 벡터로 정의하고, $\mathbf{m}K=1$라고 합니다. $\mathrm{Cat}(\cdot;\pi)$를 K 클래스에 대한 범주형 분포로 정의하며, 확률은 $\pi\in\Delta K$에 의해 주어지고, 여기서 ΔK은 K 심플렉스를 나타냅니다. 또한, $\langle\mathbf{a},\mathbf{b}\rangle$는 벡터 $\mathbf{a}$과 $\mathbf{b}$ 사이의 내적을 나타냅니다. 우리는 순서 있는 집합(튜플)을 나타내기 위해 괄호 ()를 사용하고, 순서 없는 집합을 나타내기 위해 중괄호 를 사용합니다. |A|은 집합 A의 카디널리티를 나타냅니다.

MDM은 두 가지 두드러진 순서를 특징으로 합니다: 시퀀스 순서와 노이즈 제거 순서. 우리는 순열 σ을 사용하여 이러한 순서들 간의 관계를 설명합니다. $\mathscr{P}L$을 [L]=1,⋯,L의 모든 순열 집합으로 나타냅니다. $\sigma\in\mathscr{P}L$는 순서가 있는 집합(튜플)이며 전단사 함수로도 기능합니다. $\sigma(l)$는 lth 위치에 있는 σ의 항목이고, $\sigma-1(i)$은 i 항목의 σ 위치입니다. 예를 들어, (2,4,1,3)은 1,2,3,4의 순서를 나타내며, $\sigma(2)=4$는 위치 2를 해당 항목 4에 매핑하고, $\sigma-1(4)=2$는 항목 4를 해당 위치 2에 매핑합니다.

$\mathbf{x}\in\mathscr{V}L$는 마스크 토큰이 없는 길이 L의 시퀀스를 나타내고, $\mathbf{x}\ell$는 ℓth의 $\mathbf{x}$번째 항목을 나타냅니다. 우리는 '토큰 인덱스'라는 용어를 원래 순서에서 토큰의 위치를 나타내는 데 사용합니다. 예를 들어, $\mathbf{x}l$의 토큰 인덱스는 l입니다. $(\mathbf{z}\langle i\rangle t)\langle/i\rangle t\in[0,1]\in\mathscr{V}L$은 마스크 토큰을 포함할 수 있는 길이 L의 시퀀스를 나타냅니다. $\mathscr{M}(\mathbf{z}\langle i\rangle t)=\ell|\mathbf{z}\langle/i\rangle t\ell=\mathbf{m}$는 $\mathbf{z}\langle i\rangle t$에 있는 마스크 토큰의 토큰 인덱스를 나타내고, $\mathscr{C}(\mathbf{z}\langle/i\rangle t)=\ell|\mathbf{z}\langle i\rangle t\ell\neq\mathbf{m}$은 $\mathbf{z}\langle/i\rangle t$에 있는 깨끗한 토큰의 토큰 인덱스를 나타냅니다.

$\oplus:\mathscr{V}m\times\mathscr{V}n\to\mathscr{V}m+n$는 길이 m과 n인 두 시퀀스 $\mathbf{x}=(\mathbf{x}1,\mathbf{x}2,\cdots,\mathbf{x}m)$과 $\mathbf{z}=(\mathbf{z}1,\mathbf{z}2,\cdots,\mathbf{z}n)$에 대한 연결 연산자를 나타냅니다. 연결된 시퀀스 $\mathbf{x}\oplus\mathbf{z}$가 트랜스포머에 공급될 때, $\mathbf{x}$과 $\mathbf{z}$은 독립적으로 트랜스포머에 공급될 때와 동일한 위치 임베딩을 가집니다. $\odot:\mathscr{V}m\times\mathscr{V}n\to\mathscr{V}m$는 치환 연산자를 나타냅니다. 임의의 $\mathbf{z}\in\mathscr{V}m$와 $\mathbf{x}\in\mathscr{V}n$ (여기서 m>n)에 대해, 출력 $\mathbf{y}=\mathbf{z}\odot\mathbf{x}$는 $\mathbf{y}1:n=\mathbf{x}$과 $\mathbf{y}n+1:m=\mathbf{z}n+1:m$에 의해 주어집니다.

2.1 자기회귀 모델

$\mathbf{x}$~qdata에 있는 시퀀스 $\mathscr{V}$L이 주어졌을 때, 자기회귀(AR) 모델은 결합 분포의 다음 인수분해를 정의합니다: logpθ($\mathbf{x}$)=Σt=1Llogpθ($\mathbf{x}\ell$|$\mathbf{x}$cℓ), 여기서 모델 pθ은 일반적으로 인과 트랜스포머

2.2 마스크 확산 모델

확산 모델은 순방향 손상 과정 q을 역으로 학습하여, $\mathscr{V}$L의 깨끗한 데이터 $\mathbf{x}$~qdata을 t∈[0,1]에 대해 일련의 잠재 변수 $\mathbf{z}$t로 변환하며, 각 변수는 $\mathbf{x}$의 점진적으로 더 노이즈가 많은 버전을 나타냅니다 [31, 32, 8]. MDM [26, 30, 20]에서 순방향 마스킹 과정 q은 시퀀스 $\mathbf{x}$에 걸쳐 독립적으로 인수분해됩니다. 즉, q</i>t(.|$\mathbf{x}$)=Πℓqt(.|$\mathbf{x}\ell$)이고 각 토큰 $\mathbf{x}$l는 고정된 목표 분포 Cat(.;$\mathbf{m}$)과 점진적으로 보간됩니다. 시간 t에서의 $\mathbf{z}$tℓ~qt(.|$\mathbf{x}\ell$)의 한계는 다음과 같습니다.

qt(.|$\mathbf{x}\ell$)=Cat(.;αt$\mathbf{x}\ell$+(1−αt)$\mathbf{m}$), (1)

여기서 αt∈[0,1]은 t에서 엄격하게 감소하는 함수이며 α0≈1 및 α1≈0입니다. Sahoo et al.

[$q_{s|t}$(.|₩mathbf{z}{t}^₩ell,₩mathbf{x}^₩ell)=₩begin{cases}₩text{Cat}(.;₩mathbf{z}{t}^₩ell)&₩mathbf{z}{t}^₩ell₩neq₩mathbf{m},₩ ₩text{Cat}₩left(:{₩frac{(1-₩alpha{s})₩mathbf{m}+({₩alpha_s-₩alpha_t})₩mathbf{x}^₩ell}{1-₩alpha_t}}₩right)&₩mathbf{z}_t^₩ell=₩mathbf{m}.₩end{cases}] (2)

노이즈 제거 모델 $\mathbf{x}$θ:$\mathscr{V}$L→(ΔK)L가 주어졌을 때, 시퀀스 $\mathbf{z}$s에 대한 역 마스크 해제 과정 p</i>θ(.|$\mathbf{z}$t)s|t은 다음과 같이 매개변수화됩니다.

pθ(.|$\mathbf{z}$t)s|t=ΠℓLpθℓ(.|$\mathbf{z}$t)s|t=ΠtLqs|tℓ(.|$\mathbf{z}$tℓ,$\mathbf{x}\ell$=$\mathbf{x}$θℓ($\mathbf{z}$t)). (3)

Sahoo et al.

$\mathscr{L}$MDM($\mathbf{x}$)=𝔼q,t~[0,1]αt′1−αtΣℓ∈$\mathscr{M}$($\mathbf{z}$t)log⟨$\mathbf{x}$θℓ($\mathbf{z}$t),$\mathbf{x}\ell$⟩, (4)

이는 마스킹된 토큰 $\mathscr{M}$($\mathbf{z}$t)에 대해서만 계산된 마스크 언어 모델링 손실

길이 L의 시퀀스를 생성하기 위해, 역 확산 과정은 $\mathbf{z}$t=1에서 시작하며, 여기서 ℓ=1,⋯,L에 대해 $\mathbf{z}$t=1ℓ=$\mathbf{m}$입니다. 이 과정은 T단계 동안 진행되며, 각 $\mathbf{z}$sℓ는 (3)에 정의된 pθ(.|$\mathbf{z}$t)s|t에서 독립적으로 샘플링됩니다. 일단 위치가 마스크 해제되면 고정된 상태로 유지됩니다. 여러 토큰이 병렬로 노이즈 제거될 수 있으므로, 총 네트워크 함수 평가(NFE) 수는 L보다 적을 수 있어 더 빠른 생성이 가능합니다. 그러나 $\mathbf{x}$θ($\mathbf{z}$t)의 양방향 트랜스포머로 인해 각 NFE는 비용이 많이 듭니다.

2.3 블록 노이즈 제거 확산 이산 언어 모델

블록 노이즈 제거 확산 이산 언어 모델(BD3-LM)