5가지 실험

우리는 LM1B(One Billion Words 데이터셋) *

5.1 가능도 평가

우리의 실험은 Eso-LM이 LM1B 및 OWT에서 확산 모델 중 최첨단 혼란도를 달성하며, MDM과 AR 혼란도 사이의 더 세밀한 보간을 제공함을 보여줍니다(표 1 및 표 2).

실험 설정 우리는 Eso-LM을 선도적인 마스크 확산 모델(MDLM *

결과 우리 방법의 경우 PPL은 (7)을 사용하여 계산됩니다. LM1B에서 우리는 Eso-LM (A)를 $\alpha_0 \in \{0.0625, 0.125, 0.25, 0.5, 1.0\}$로, Eso-LM (B)를 $\alpha_0 = 1$로 훈련합니다. Eso-LM (A)가 MDLM과 AR 혼란도 사이를 효과적으로 보간한다는 것을 발견했습니다. 놀랍게도, 마스크 토큰에 대한 양방향 어텐션을 인과적 마스크로 대체하여 MDM을 수정한 Eso-LM (A)는 $\alpha_0 = 1$에서 MDLM보다 ≈ 1 PPL 더 나은 성능을 보입니다. 이러한 개선은 앞서 설명한 저분산 훈련 손실(low-variance training loss)에 기인할 수 있습니다. 대조적으로, Eso-LM (B)는 깨끗한 토큰(clean tokens) 사이에 인과적 종속성(causal dependencies)을 도입하여 $\alpha_0 = 1$에서 Eso-LM (A)보다 ≈ 4 PPL 성능이 저하됩니다. 이는 Eso-LM (A)의 깨끗한 토큰에 대한 양방향 어텐션이 Eso-LM (B)의 인과적 어텐션보다 엄밀히 더 표현력이 높기 때문에 예상된 결과입니다. OWT에서 Eso-LM (B)는 확산 단계에서 KV 캐싱을 지원하는 유일한 모델(BD3-LM 포함)이므로 특히 설득력이 있습니다. $\alpha_0 \in \{0.0625, 0.125, 0.25, 0.5, 1.0\}$으로 훈련된 이 모델은 AR과 MDM 혼란도 사이의 부드러운 보간을 보여줍니다(표 2). LM1B와 마찬가지로, Eso-LM (A)는 OWT에서 MDLM과 경쟁력을 유지합니다.

5.2 생성 속도

우리의 정성적 평가 실험은 Eso-LM이 KV 캐싱을 지원하는 이전 확산 기반 방법보다 3–4× 빠르며, KV 캐싱을 지원하지 않는 MDM보다 약 65× 더 빠르다는 것을 보여줍니다.

실험 설정 MDLM과 같은 확산 모델은 양방향 어텐션 사용으로 인해 KV 캐싱을 지원하지 않습니다. BD3-LM과 같은 준-자기회귀 모델(semi-autoregressive models)은 토큰 블록을 자기회귀적으로 생성하고 완료된 블록을 캐싱함으로써 부분적인 KV 캐싱을 가능하게 하지만, 확산 중인 현재 블록에 대한 캐싱은 여전히 부족합니다. 이와 대조적으로, 우리 방법은 확산 단계에서 KV 캐싱을 독특하게 지원합니다. 우리는 컨텍스트 길이 $L \in \{2048, 8192\}$에서 우리 방법인 Eso-LM (B)와 MDLM 및 BD3-LM의 추론 시간(inference times)을 *

표 1: LM1B의 테스트 혼란도(PPL; ↓). *He 외

	PPL (↓)
Autoregressive	
Transformer†	22.83
Diffusion	
D3PM Uniform [2]	137.90$
D3PM Absorb [2]	76.90$
Diffusion-LM* [12]	118.62$
DiffusionBert [7]	63.78
SEDD Absorb† [15]	32.71$
SEDD Uniform$ [15]	40.25$

	PPL (↓)
MDLM‡ [26]	31.78
UDLM‡ [29]	36.71
DUO‡ [27]	33.68
Interpolating diffusion and autoregressive	
BD3-LMs† [1]	
L' = 16	30.60
L' = 8	29.83
L' = 4	28.23
Eso-LM (B) (Ours)	
α0 = 1.0	35.00
Eso-LM (A) (Ours)	
α0 = 1.0	30.96
α0 = 0.5	30.51
α0 = 0.25	28.44
α0 = 0.125	25.97
α0 = 0.0625	24.51

표 2: 250K 훈련된 모델의 OWT 테스트 혼란도(PPL; ↓). ‡

	PPL (↓)
Autoregressive	
Transformer	17.90$
Diffusion	
SEDD Absorb [15]	26.81$
MDLM [26]	25.76$
UDLM [29]	30.52$
DUO [27]	27.14$
Interpolating diffusion and autoregressive	
BD3-LMs [1]	
L' = 16	23.57†
Eso-LM (A) (Ours)	
α0 = 1	26.21
Eso-LM (B) (Ours)	
α0 = 1	30.14
α0 = 0.5	27.85
α0 = 0.25	24.73

	PPL (↓)
α0 = 0.125	21.87

표 3: 모든 방법에서 NFE가 L으로 설정된 시퀀스 길이 L∈{2048,8192}에 대한 샘플링 시간(↓, 초). 보고된 값은 5회 실행의 평균입니다.

Method	L = 2048	L = 8192
AR (Oracle)	13.30.9	54.00.2
MDLM	201.30.4	5438.33.3
BD3-LM (L' = 4)	24.30.7	312.01.7
BD3-LM (L' = 16)	21.30.1	268.11.2
Eso-LM (B)	14.60.3	82.10.3

결과 표 3에서 볼 수 있듯이, KV 캐싱이 없는 MDLM과 비교할 때, Eso-LM (B)는

L=2048에서 ~14×배 빠르며, L=8192에서 ~65×배 빠릅니다. 부분적으로 캐싱을 지원하는 BD3-LM과 비교할 때, Eso-LM (B)는 L=8192에서 BD3-LM (L′=16)보다 ~3.2×배 빠르고 BD3-LM (L′=4)보다 ~3.8×배 빠릅니다. 이러한 속도 향상은 KV 캐싱과 스케줄러 S에서 비롯됩니다. 스케줄러는 순방향 통과(forward pass)를 잡음 제거(denoised)되어야 하는 마스크 토큰과 이전에 예측된 토큰으로 제한하여 중복 계산을 피하는데, 이는 BD3-LM에 없는 기능입니다. NFEs를 L로 제한하므로, 우리 방법은 지연된 KV 재사용(KV reuse) — 즉, 마지막에서 두 번째 잡음 제거 단계에서만 가능 — 으로 인해 AR 모델보다 느리지만, 전반적인 효율성은 이전 확산 기반 기준선(Sec. 4.2.2 참조)을 여전히 능가합니다.

5.3 생성 품질

우리의 샘플링 실험은 (1) Eso-LM이 샘플링 속도 및 품질의 파레토 프론티어(Pareto frontier)에서 새로운 SOTA를 구축하고(그림 4), (2) 높은 NFE에서 모든 이전 확산 모델보다 더 높은 품질의 샘플을 생성하며, (3) 이전 보간 확산 방법인 BD3-LM과 달리 낮은 NFE에서 모드 붕괴(mode collapse)를 겪지 않음을 보여줍니다(그림 3).

실험 설정 우리는 α0train∈{0.125,0.25,1}으로 Eso-LM (B)를 훈련하고, NFE를 제어하기 위해 다양한 (α0eval,T)∈{0.0625,0.25,0.5,1}×{16,128,1024}로 샘플을 생성합니다 (NFEs = |S|). MDLM 및 BD3-LM은 Sahoo et al.